

Informe técnico

Plataforma de segmentación y Recomendación de Supermercados

Procesamiento de Datos Distribuidos

Isabella Huila Cerón

Daniela Londoño Candelo

Universidad Icesi, Cali

Junio de 2026

I. DESCRIPCIÓN DE LOS DATOS

1.1 Contexto de Negocio

La plataforma procesa transacciones históricas de un supermercado con múltiples sucursales. El objetivo es transformar datos transaccionales crudos en inteligencia accionable para tres propósitos principales:

- Segmentación de clientes: Identificar grupos de compra homogéneos con base en su comportamiento histórico.
- Recomendaciones de compra: Sugerir categorías complementarias a los clientes según los patrones de co-ocurrencia en canastas.
- Análisis exploratorio: Entender patrones de compra por tiempo, sucursal y categoría para apoyar decisiones comerciales y operativas.

1.2 Fuente de Datos

Origen: Dataset histórico de 4 sucursales de supermercado.

Período: 1 de enero – 30 de junio de 2013 (6 meses).

Volumen: 1.1 millones de transacciones.

Sucursal	ID Interno	Rol
Sucursal A	102	Principal
Sucursal B	103	Complementaria
Sucursal C	107	Regional
Sucursal D	110	Distribuida

1.3 Estructura de los Datos

1.3.1 Formato Primario: Canasta de Compra

Cada transacción se representa como una fila que contiene la fecha, el identificador de sucursal, el identificador de cliente y la lista de categorías compradas. Por ejemplo:

2013-01-15 | 102 | 5478 | 5 10 23 18

Campo	Tipo	Descripción	Restricción
Date	Fecha	Día de la transacción	Sin datos de hora
Store ID	Entero	Identificador de sucursal	4 valores únicos
Customer ID	Entero	Identificador de cliente	Variable por período
Categories	Lista[Entero]	Categorías compradas	50 categorías totales
Basket Size	Entero	# Categorías en canasta	1-N (derivado)

1.3.2 Implicaciones para el Análisis

Los datos están agregados a nivel de categoría, no a nivel de producto individual. Esto establece el alcance del análisis:

- Se puede analizar qué combinaciones de categorías compra un cliente y con qué frecuencia.
- No es posible identificar qué productos específicos adquirió cada cliente dentro de una categoría.
- No hay información monetaria directa: el valor de compra se aproxima mediante la diversidad y frecuencia de categorías.

1.4 Catálogo de Productos

Complementando las transacciones, el sistema dispone de un catálogo con 50 categorías de producto (Lácteos, Jugos, Pastas, Higiene, Carnes procesadas..etc). Cada producto se asigna a exactamente una categoría, con aproximadamente 50 productos por categoría. El catálogo se utiliza principalmente para enriquecer los resultados con nombres legibles de categoría y para contextualizar las recomendaciones en el motor FP-Growth.

1.5 Variables Clave Derivadas

A partir de los datos crudos, el pipeline deriva seis características transversales que alimentan los modelos de segmentación y recomendación:

Variable	Fórmula	Interpretación Empresarial
frequency	# de transacciones únicas por cliente	Lealtad / Asiduidad del cliente
unique_categories	# de categorías distintas compradas	Diversidad de cartera de compra
total_categories_bought	Suma de # categorías por transacción	Volumen acumulado de categorías
avg_basket_size	$\text{total_categories} / \text{frequency}$	Tamaño promedio de canasta por visita
recency_days	Días desde la última compra	Engagement / Inactividad actual
active_days	# de días únicos de compra	Consistencia temporal del cliente

II. METODOLOGÍA DE ANÁLISIS

2.1 Arquitectura del Pipeline de Datos

El sistema implementa una arquitectura de cinco capas que procesa los datos desde su ingesta hasta su presentación al usuario final:

Capa	Componente	Descripción
1 Ingesta	PySpark 3.5	Lectura de CSVs, validación de esquema, parseo de canastas

Capa	Componente	Descripción
2 Almacenamiento	Parquet Particionado	Dos representaciones: BASKET y LONG, particionadas por sucursal/mes
3 Modelado	K-Means + FP-Growth	Segmentación de clientes y descubrimiento de reglas de asociación
4 API	FastAPI + DuckDB	Exposición de resultados vía endpoints REST tipados con OpenAPI
5 Presentación	React + Vite + Recharts	Dashboard interactivo con visualizaciones dinámicas

2.2 Fase 1: Ingesta y Limpieza de Datos

El sistema almacena los datos en dos representaciones equivalentes en formato Parquet particionado:

- Representación BASKET (por transacción): óptima para Market Basket Analysis con FP-Growth.
- Representación LONG (por línea de detalle): óptima para agregaciones, time-series y análisis por dimensión con K-Means.

El particionamiento por `store_id` y `year_month` reduce el escaneo de datos entre un 70% y un 90% en consultas filtradas por sucursal o mes.

2.3 Fase 2: Ingeniería de Características para Segmentación (K-Means)

Para cada cliente, el pipeline calcula un vector de las seis características derivadas descritas en la sección 1.5. Dado que las variables tienen rangos heterogéneos (`frequency`: 1–500 vs. `recency_days`: 0–180), se aplica `StandardScaler` (media = 0, desviación estándar = 1) antes del entrenamiento, lo que evita que variables de mayor magnitud dominen la métrica de distancia euclidiana.

El sistema evalúa valores de `K` entre 2 y 6 usando la métrica `Silhouette Score`. Esta métrica compara la cohesión intra-cluster con la separación inter-cluster, con valores entre -1 y +1 donde +1 es óptimo. El `K` con mayor `Silhouette Score` es seleccionado como configuración final.

2.4 Fase 3: Descubrimiento de Reglas de Asociación (FP-Growth)

FP-Growth opera sobre la representación BASKET para descubrir qué categorías tienden a comprarse juntas en la misma transacción. El algoritmo construye un FP-Tree comprimido (10–20x más eficiente que Apriori), extrae itemsets frecuentes y genera reglas bajo los siguientes umbrales:

- `MinSupport` = 0.01: al menos el 1% de las canastas deben contener la combinación.
- `MinConfidence` = 0.30: al menos el 30% de confianza para incluir la regla.

Para recomendar a un cliente `X` con historial reciente `{A, B, C}`, el motor busca todas las reglas cuyo antecedente esté contenido en `{A, B, C}`, extrae los consecuentes no comprados recientemente y los rankea por Lift descendente.

2.5 Fase 4: Exposición de Resultados (API REST)

FastAPI expone los resultados de los modelos mediante tres grupos de endpoints:

Grupo	Endpoints principales	Propósito
Segmentación	/api/v1/segmentation/clusters /api/v1/segmentation/scatter /api/v1/segmentation/customers/{id}/cluster	Perfiles de cluster, proyección PCA, clasificación individual
Recomendaciones	/api/v1/recommendations/customer/{id} /api/v1/recommendations/category/{id}	Recomendaciones personalizadas y por categoría
Analytics	/api/v1/analytics/summary /api/v1/analytics/time-series /api/v1/analytics/boxplot	KPIs, series de tiempo, distribuciones

2.6 Capa de Presentación: Dashboard Interactivo

El frontend, construido con React + TypeScript + Vite + Recharts, expone cinco páginas funcionales:

Página	Visualizaciones principales
Executive Summary	KPIs globales, tendencias generales
Analytics Exploration	Boxplot, heatmap de correlaciones, histogramas, heatmap temporal
Segmentation	Scatter plot PCA 2D, perfiles de cluster comparativos
Recommendations	Reglas por categoría o cliente, ranking por lift
Data Management	Ingesta de nuevas transacciones vía REST POST, estado de reentrenamiento

III. PRINCIPALES HALLAZGOS VISUALES

3.1 Volumen y Popularidad de Categorías

El análisis de volumen de compra revela una distribución concentrada en pocas categorías de alto desempeño. Las gráficas siguientes muestran el ranking de las 10 categorías con mayor volumen acumulado durante el período enero–junio 2013, junto con su participación porcentual en el total de transacciones.




Figura 1. Top 10 categorías por volumen total de líneas de compra.



Figura 2. Distribución porcentual de las 10 categorías más compradas.

Los hallazgos principales en cuanto a volumen son:

- Carnes Procesadas al Vacío lidera con un 13.67% de participación, seguida de Verduras Raíz, Tubérculo y Bulbos, Verduras de Frutos y Cuidado de la Ropa (aproximadamente 12% cada una), conformando un bloque dominante de consumo.
- Jugos y Verduras de Hojas se sitúan en torno al 8.65%, indicando un perfil de compra con fuerte componente de frescos y bebidas.

- Las 10 categorías principales concentran más del 91% del volumen total, evidenciando que la gran mayoría del surtido desempeña un rol de soporte o compra esporádica.
- Legumbres Verdes ocupa la décima posición con apenas 2.21%, señalando una categoría de nicho que podría beneficiarse de estrategias de impulso o merchandising diferenciado.

3.2 Clientes con Mayor Actividad Transaccional

El siguiente gráfico muestra los 10 clientes con mayor número de transacciones registradas en el período, junto con la cantidad de categorías únicas visitadas. Este doble indicador permite distinguir entre clientes de alta frecuencia con canastas estrechas y clientes de alta frecuencia con mayor diversidad de compra.




Figura 3. Top 10 clientes por número de transacciones y categorías únicas.

El cliente #440157 es el más activo con cerca de 440 transacciones en el semestre, equivalente a compras casi diarias. Se observa que en la mayoría de los clientes del top 10, el número de transacciones supera visiblemente a las categorías únicas, lo que indica que los compradores frecuentes tienden a repetir las mismas categorías en lugar de ampliar su canasta. Esto representa una oportunidad directa para el motor de recomendaciones: incentivar la exploración de nuevas categorías complementarias en este segmento de alto valor.

3.3 Comportamiento Temporal de las Transacciones

Las series de tiempo permiten entender los ritmos de compra a nivel diario, semanal y mensual, revelando patrones que complementan el análisis de segmentación.



Figura 4. Serie de tiempo diaria: transacciones y líneas de categoría (enero–junio 2013).



Figura 5. Serie de tiempo semanal



Figura 6. Serie de tiempo mensual

Las tres granularidades revelan patrones complementarios:

- Volumen estable: Las transacciones diarias oscilan entre 5,000 y 12,000 con un promedio sostenido a lo largo del semestre, sin estacionalidad pronunciada entre enero y mayo.
- Caída al cierre de junio: Tanto transacciones como líneas de categoría presentan una caída pronunciada al final del período (30 de junio), lo que corresponde al límite del dataset y no necesariamente a un fenómeno comercial.
- Ciclo semanal visible: La vista semanal muestra picos recurrentes que sugieren variabilidad ligada al calendario, posiblemente asociada a fines de semana o quincenas de pago.
- Consistencia mensual: El volumen mensual se mantiene entre 800,000 y 900,000 líneas de categoría, con un leve repunte en marzo y abril.

3.4 Días Pico: Heatmap por Día de Semana y Día del Mes



Figura 7. Mapa de calor de transacciones por día de semana vs. día del mes.

El mapa de calor revela patrones diferenciados por posición en el mes y día de la semana:

- Los sábados y domingos concentran los tonos más intensos (azul oscuro) en las primeras semanas del mes, asociados posiblemente a fechas de pago quincenales o inicio de mes.
- Los días 1, 15 y alrededor del 30 presentan actividad elevada, consistente con comportamientos de compra ligados a ciclos de pago típicos en Colombia.
- Los días entre semana (martes a viernes) muestran niveles de actividad más homogéneos y moderados, con menor variabilidad intersemanal.
- Los lunes registran la menor densidad transaccional en la mayoría de las semanas, lo cual puede orientar decisiones de personal y logística de abastecimiento.

3.5 Distribución del Tamaño de Canasta

Los boxplots permiten visualizar la dispersión y asimetría del tamaño de canasta (número de categorías distintas por transacción), tanto a nivel de categoría de producto como a nivel de cliente individual.



Figura 8. Distribución del tamaño de canasta por categoría de producto




Figura 9. Distribución del tamaño de canasta por cliente

Observaciones clave:

- La mediana general del tamaño de canasta se sitúa entre 5 y 8 categorías por transacción, con relativa consistencia entre categorías y clientes.
- Queso y Pasabocas presentan los rangos intercuartílicos más amplios (5 a 12), indicando que los clientes que los compran tienden a hacer compras más completas.
- Legumbres Verdes muestra cajas más estrechas y medianas bajas (6 categorías), coherente con ser una categoría de compra más puntual y menos acompañada.
- A nivel de cliente, el cliente 522427 presenta una canasta mediana baja con poco rango, mientras que clientes como 803712 o 63951 muestran mayor amplitud, reflejando un perfil de compra más diversificado.

3.6 Correlación entre Métricas de Cliente



Figura 10. Matriz de correlación entre frecuencia, categorías únicas y tamaño de canasta promedio.

La matriz de correlación muestra las relaciones entre las tres métricas clave de comportamiento de cliente:

- Frecuencia - Categorías únicas ($r = 0.61$): Correlación moderada-alta. Los clientes más frecuentes tienden a explorar más categorías a lo largo del tiempo, aunque no necesariamente en cada visita individual.
- Categorías únicas - Tamaño de canasta ($r = 0.76$): Correlación alta. Los clientes con mayor diversidad acumulada también hacen canastas más grandes por transacción, lo que define el perfil del "comprador integral".
- Frecuencia - Tamaño de canasta ($r = 0.28$): Correlación débil. Comprar frecuentemente no implica hacer canastas más grandes; el comportamiento tiende a ser más habitual que exploratorio.

Esta estructura de correlaciones valida el uso conjunto de las seis variables en K-Means: la varianza explicada no es redundante y cada dimensión aporta información diferenciada para la segmentación.

IV. RESULTADOS DEL MODELO DE SEGMENTACIÓN Y RECOMENDACIÓN

4.1 Modelo de Segmentación K-Means

4.1.1 Descripción Conceptual

El modelo K-Means tiene como objetivo particionar la base de clientes en K grupos homogéneos según su perfil de compra. Responde a la pregunta de negocio: ¿Cuáles son los diferentes tipos de clientes que tenemos y cuáles son sus características?

El algoritmo opera en tres fases iterativas:

1. asignación de cada cliente al centroide más cercano por distancia euclidiana,
2. recálculo del centroide como la media del cluster, y
3. repetición hasta convergencia (cuando la inercia cambia menos del 1% entre iteraciones).

La entrada es una matriz de hasta 300,000 clientes × 6 características normalizadas, y la salida es la asignación de un cluster_id a cada cliente junto con los centroides finales.

4.1.2 Selección del K Óptimo

El pipeline evaluó valores de K entre 2 y 6 usando la métrica Silhouette Score sobre los vectores de cliente normalizados. Esta métrica compara para cada punto la distancia promedio intra-cluster a(i) con la distancia promedio al cluster más cercano b(i):

$$\text{silhouette}(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

Silhouette Score	Interpretación
> 0.6	Clusters bien definidos y compactos
0.4 – 0.6	Clusters aceptables
< 0.3	Clusters solapados, revisar K

El proceso determinó K = 2 como la configuración óptima, con el mayor nivel de cohesión intra-cluster y separabilidad inter-cluster. Este resultado indica que la base de clientes presenta dos comportamientos de compra claramente diferenciados.

4.1.3 Proyección PCA 2D

Para visualizar la separación entre segmentos, se aplicó PCA (Análisis de Componentes Principales) para reducir el espacio de 6 dimensiones a dos componentes principales. El primer componente captura principalmente la varianza asociada a frecuencia y categorías únicas (45% de la varianza total), mientras que el segundo recoge la recencia y tamaño de canasta (25%), reteniendo en conjunto aproximadamente el 70% de la información original.




Figura 11. Mapa de clientes Proyección PCA 2D coloreada por clúster K-Means ($K = 2$).

La proyección confirma una separación razonablemente clara entre los dos grupos. El clúster rojo (Comprador regular) se concentra en valores bajos del Componente Principal 1 con mayor dispersión vertical, mientras que el clúster azul (Frecuente y activo) se extiende hacia valores más altos del eje horizontal, asociados a mayor frecuencia y diversidad de compra. La zona de solapamiento en el centro del scatter representa clientes en transición entre ambos perfiles.

4.1.4 Perfiles de los Clústeres



Figura 12. Perfiles promedio de los dos clústeres identificados por K-Means.

Característica	Frecuente y Activo (Azul)	Comprador Regular (Rojo)
Número de clientes	28,725	95,433
Participación en la base	23%	77%
Frecuencia promedio	22.6 transacciones	3.6 transacciones

Característica	Frecuente y Activo (Azul)	Comprador Regular (Rojo)
Categorías únicas	14.5	7.3
Tamaño canasta promedio	6.0 categorías	4.6 categorías
Días desde última compra	20 días	68 días

Interpretación de cada segmento:

- Frecuente y Activo (28,725 clientes , 23% de la base): Clientes de alto valor con visitas muy frecuentes (22 veces en el semestre, casi una visita semanal), alta diversidad en categorías compradas (14.5 únicas) y recencia reciente (última compra hace 20 días en promedio). Son la columna vertebral del negocio y los candidatos prioritarios para programas de fidelización, recomendaciones personalizadas de alto impacto y comunicaciones de alto valor percibido.
- Comprador Regular (95,433 clientes, 77% de la base): Mayoría de la base, con comportamiento más esporádico (3.6 visitas en el semestre) y canastas más pequeñas. Con 68 días desde la última compra en promedio, existe un riesgo latente de churn. Este segmento tiene el mayor potencial de crecimiento: pequeños incrementos en frecuencia o tamaño de canasta generan impacto significativo dado su volumen.

4.1.5 Etiquetado Semántico de Clusters

El sistema asigna etiquetas comprensibles a cada cluster mediante un score compuesto que combina frecuencia normalizada y recencia normalizada. Esto facilita la comunicación entre los equipos técnico y comercial, permitiendo referirse a "Compradores Frecuentes" y "Compradores Regulares" en lugar de "Cluster 0" y "Cluster 1".

4.2 Motor de Recomendaciones (FP-Growth)

4.2.1 Descripción Conceptual

FP-Growth descubre patrones de compra conjunta en el Conjunto de transacciones. Responde a la pregunta de negocio: ¿Qué categorías se compran juntas? ¿Podemos hacer recomendaciones basadas en el historial del cliente?

4.2.2 Métricas de las Reglas

Métrica	Rango	Interpretación
Support	0 – 1	Frecuencia relativa de la regla en todas las canastas del período
Confidence	0 – 1	P(consecuente antecedente): probabilidad de compra conjunta
Lift	0 – ∞	Razón entre probabilidad observada vs. esperada bajo independencia estadística

Umbral aplicados: MinSupport = 0.01 (1% de canastas) y MinConfidence = 0.30 (30% de confianza mínima). Un Lift > 1 indica asociación positiva; Lift > 2 indica una asociación sólida y accionable para recomendaciones.

4.2.3 Ejemplo de Regla Descubierta

Antecedente	Consecuente	Support	Confidence	Lift	Lectura
{Bebidas, Snacks}	{Helados}	2.5%	68%	2.85	Comprar Bebidas y Snacks hace 2.85× más probable comprar Helados

4.2.4 Reglas Representativas Descubiertas

Antecedente	Consecuente	Support	Confidence	Lift	Estrategia
Carnes Procesadas	Condimentos	7.2%	64%	2.3	Preparación conjunta
Verduras de Frutos	Jugos	5.8%	58%	1.9	Complemento nutricional
Jugos + Frutos	Lácteos	4.1%	61%	2.1	Desayuno completo
Cuidado de Ropa	Aromas. Medicinales	3.6%	52%	1.7	Higiene del hogar
Pastas Comestibles	Condimentos	6.3%	70%	2.4	Venta cruzada clásica

4.2.5 Recomendaciones Personalizadas

Para un cliente con historial reciente de categorías {A, B, C}, el motor opera así:

- Busca reglas cuyo antecedente esté contenido en {A, B, C}.
- Extrae los consecuentes que el cliente no ha comprado recientemente.
- Rankea por Lift descendente: mayor lift = asociación estadísticamente más fuerte = mejor recomendación.

Ejemplo de recomendación en tiempo real para dos clientes del top 10:

Cliente	Categorías recientes	Rec. #1	Rec. #2	Rec. #3
#440157	Carnes + Pastas	Condimentos (lift 2.4)	Verduras Raíz (lift 1.8)	Jugos (lift 1.6)
#576930	Verduras + Frutos	Jugos (lift 1.9)	Lácteos (lift 2.1)	Pasabocas (lift 1.5)

4.3 Métricas de Éxito del Modelo

4.3.1 Para K-Means

Métrica	Umbral Óptimo	Umbral Aceptable	Alerta
Silhouette Score	> 0.6	0.4 – 0.6	< 0.3
Inercia (WSSSE)	Minimizada	—	Muy alta
Tamaño cluster (ratio)	30-40% cada uno	20-50%	< 10% o > 70%
Varianza retenida PCA	> 70%	50-70%	< 50%

4.3.2 Para FP-Growth

Métrica	Valor Objetivo	Señal de Alerta
Número de reglas generadas	50 – 500 reglas	< 10 (escaso interés de asociación)
Confidence promedio	> 40%	< 30% (reglas débiles)
Lift promedio	> 1.5	< 1.3 (categorías no asociadas)
% reglas con lift > 2.0	> 20%	< 5% (poco apalancamiento)
Cobertura de transacciones	> 60%	< 40% (reglas muy específicas)

V. CONCLUSIONES Y POSIBLES APLICACIONES EMPRESARIALES

5.1 Síntesis de Resultados

La plataforma de análisis transforma 1.1 millones de transacciones de supermercado en inteligencia accionable a través de dos modelos complementarios. Los resultados obtenidos permiten extraer las siguientes conclusiones centrales:

- La base de clientes se divide en dos segmentos claramente diferenciados: un 23% de compradores frecuentes y activos (alta frecuencia, alta diversidad, alta recencia) y un 77% de compradores regulares con comportamiento más esporádico. Esta asimetría es estructuralmente similar a la distribución 80/20 observada en retail, donde una minoría de clientes genera la mayoría del valor operativo.
- Las categorías de mayor peso (Carnes Procesadas, Verduras, Cuidado de Ropa, Jugos) concentran más del 91% del volumen total, definiendo un surtido "núcleo" sobre el cual construir estrategias de tráfico y expansión de canasta.
- Existen patrones temporales sólidos y accionables: picos de actividad al inicio y mediados de mes (coherentes con ciclos de pago quincenales), mayor actividad los sábados y domingos, y menor flujo transaccional los lunes.
- Las reglas de asociación descubiertas por FP-Growth revelan complementariedades naturales entre categorías (Carnes–Condimentos, Frutas–Lácteos, Pastas–Condimentos) que constituyen la base objetiva y estadísticamente validada de un motor de recomendaciones personalizado.
- La correlación alta entre diversidad de categorías y tamaño de canasta ($r = 0.76$) confirma que ampliar la gama de categorías compradas incrementa el ticket por visita, validando la relevancia estratégica de las recomendaciones cruzadas para el negocio.

5.2 Aplicaciones Empresariales

5.2.1 Fidelización Diferenciada por Segmento

La segmentación en dos perfiles permite diseñar programas de lealtad ajustados al comportamiento real de cada grupo:

Segmento	Objetivo Estratégico	Táctica Sugerida
Frecuente y Activo (28,725 clientes)	Retener y maximizar valor	Programa VIP con beneficios escalonados, acceso anticipado a promociones, recomendaciones personalizadas semanales por canal digital.
Comprador Regular (95,433 clientes)	Reactivar y aumentar frecuencia	Cupones de reactivación para clientes con recencia > 60 días, incentivos por segunda visita en el mes, comunicaciones enfocadas en categorías de interés conocido.

5.2.2 Venta Cruzada y Optimización de Canasta

Las reglas de asociación con mayor Lift ofrecen la guía más objetiva para acciones de venta cruzada:

- **Layouting físico:** Colocar categorías frecuentemente compradas juntas en zonas adyacentes (Pastas próximas a Condimentos, Carnes próximas a Verduras Raíz) para incrementar el tamaño de canasta por proximidad y visibilidad.
- **Recomendaciones digitales:** Desplegar sugerencias en app o pantallas de autoservicio usando el motor FP-Growth en tiempo real, especialmente para el segmento Frecuente y Activo que compra con regularidad predecible.
- **Combos y pack promotions:** Diseñar ofertas combinadas basadas en las reglas de mayor support y confidence (e.g., combos de desayuno con Frutas + Lácteos + Jugos; packs de fin de semana con Carnes + Condimentos).

5.2.3 Gestión de Inventario y Abastecimiento

El análisis temporal y de volumen por categoría permite mejorar la planificación de inventario:

- Aumentar disponibilidad de las categorías núcleo (Top 10 por volumen) en los períodos pico identificados: inicio y mediados de mes, y fines de semana.
- Ajustar los niveles de stock de categorías de nicho (Legumbres Verdes, Aromáticas Medicinales) según la demanda real observada, evitando sobreinventario inmovilizado.
- Planificar recepciones de mercancía en los días de menor actividad transaccional (lunes) para minimizar la interferencia con la operación de cara al cliente.

5.2.4 Comunicaciones de Marketing Segmentadas

El conocimiento del perfil de cada segmento habilita comunicaciones más relevantes y eficientes:

- Para el segmento Frecuente y Activo: mensajes de alto valor percibido, acceso exclusivo, novedades de categorías que ya compran frecuentemente y alertas de stock de productos en sus categorías habituales.
- Para el segmento Comprador Regular: mensajes de reactivación, destacando categorías populares que aún no han comprado en el período reciente, con base en las reglas de asociación disponibles.
- **Temporización:** concentrar campañas digitales en los días 1 y 15 del mes para capitalizar los picos naturales de compra, y usar los domingos como el día de mayor probabilidad de impacto transaccional.

5.2.5 Monitoreo Continuo y Reentrenamiento

La plataforma está diseñada para operación continua y sostenible:

- Los modelos K-Means y FP-Growth pueden reentrenarse desde la interfaz de gestión del dashboard mediante los endpoints /retrain, cuando se incorporen nuevos datos o cuando el Silhouette Score descienda por debajo del umbral de 0.4.
- El particionamiento Parquet por sucursal y mes garantiza que el reentrenamiento sobre nuevos datos sea eficiente, sin necesidad de reprocesar el histórico completo.
- Se recomienda un ciclo de reentrenamiento mensual alineado con el período natural de los datos, y una revisión trimestral de las etiquetas de segmento para validar su vigencia comercial.

5.3 Limitaciones y Próximos Pasos

El alcance actual de la plataforma presenta limitaciones que deben considerarse al interpretar los resultados y al planificar la evolución del sistema:

- Ausencia de información monetaria: Los datos no incluyen precios ni cantidades, por lo que el valor de un cliente se aproxima por frecuencia y diversidad, no por ticket monetario. La integración de datos de precio permitiría calcular métricas RFM (Recency, Frequency, Monetary) completas, enriqueciendo significativamente los segmentos.
- Granularidad de categoría vs. producto: El análisis opera sobre las 50 categorías del catálogo, no sobre los 2,500 productos individuales. Las reglas de asociación son válidas a nivel de categoría; para recomendaciones a nivel de SKU se requeriría enriquecer el dataset con identificadores de producto en las transacciones.
- Período limitado de 6 meses: El dataset cubre enero–junio 2013, lo que impide detectar estacionalidad anual (navidad, semana santa, temporada escolar). Un año completo de datos habilitaría una planificación de temporadas más robusta.
- Modelo de 2 segmentos: Con $K = 2$, los perfiles identificados son robustos pero relativamente amplios. A medida que crezca la base de clientes o se incorpore información adicional (datos demográficos, canal de compra, historial de promociones), se podría explorar una segmentación más granular con $K = 3$ o $K = 4$.